Resumen de las principales herramientas de evaluación de riesgo de sesgo y calidad metodológica

Introducción

Cuándo se usan, qué dominios cubren, ventajas y límites, y una propuesta de flujo de trabajo para tu revisión (incluyendo qué usar para estudios ML, gemelos digitales, diagnósticos y observacionales). También incluyo referencias clave para cada herramienta.

Principio básico

Primero debemos identificar el diseño de cada estudio. La elección de la herramienta depende del diseño (RCT, no-RCT de intervención, observacional: cohortes / case-control / cross-sectional, estudios diagnósticos, estudios de predicción/ML, mediciones/propiedades del instrumento, etc.).

Tipos de diseños experimentales

Los artículos en general reportan resultados bajo diferentes diseños experimentales y que deben ser identificados a partir de la información de los resúmenes o documentos completos de los artículos

Ensayo clínico aleatorizado (Randomized Controlled Trial, RCT)

Definición: participantes asignados aleatoriamente a dos o más grupos (intervención vs control) para evaluar efecto de una intervención.

Keywords: “randomized”, “random allocation”, “randomised”, “double-blind / single-blind”, “placebo”, “control group”, “trial”.

Busca estas palabras/frases en título/abstract/métodos:

- “random*” → RCT probable
- “controlled” + “trial” → RCT o non-RCT controlado.

Herramientas principales: RoB 2 (Risk of Bias 2)

Recursos: RoB 2: Sterne et al., 2019. https://www.bmj.com/content/366/bmj.l4898 ; herramientas y guía disponibles en el sitio web de Cochrane (RoB 2: Excel/interactive tool).

Ensayo no aleatorizado / Cuasi-experimental (Non-randomized intervention / Quasi-experimental)

Definición: comparación de intervención vs control sin asignación aleatoria (p. ej. asignación por clínica, por periodo temporal).

Keywords: "non-randomized", "quasi-experimental", "before-after", "controlled before-after", "assignment by clinician".

Herramienta principal: ROBINS-I

ROBINS-I: Sterne et al., 2016. https://www.bmj.com/content/355/bmj.i4919 ; Cochrane guidance.

Estudio de cohorte (cohort study) — prospectivo o retrospectivo

Definición: sigue a un grupo (cohorte) a lo largo del tiempo para observar la incidencia de outcomes según la exposición.

Prospectivo: reclutan y siguen hacia delante;

Retrospectivo: usan registros pasados.

Keywords: "cohort", "follow-up", "prospective", "retrospective", "incidence", "longitudinal".

Señales textuales rápidas en abstract / métodos para clasificar

- "prospective", "follow-up", "cohort" → cohorte.

Herramientas: Newcastle–Ottawa Scale (NOS) / adaptaciones

Newcastle–Ottawa Scale (NOS): Wells et al. (Ottawa)
— https://www.ohri.ca/programs/clinical_epidemiology/oxford.asp

Newcastle-Ottawa Scale (NOS) | Ottawa Hospital Research Institute

Estudio caso–control (case–control)

Definición: seleccionan casos con el outcome y controles sin el outcome, comparan exposiciones pasadas.

Keywords: "case–control", "cases and controls", "odds ratio", "retrospective".

Señales textuales rápidas en abstract / métodos para clasificar

- “case-control”, “odds ratio” → caso–control.
- “case report / case series” → caso(s).

Herramientas: Newcastle–Ottawa Scale (NOS) / adaptaciones

- Newcastle–Ottawa Scale (NOS): Wells et al. (Ottawa)
  — https://www.ohri.ca/programs/clinical_epidemiology/oxford.asp

  Newcastle-Ottawa Scale (NOS) | Ottawa Hospital Research Institute

Estudio transversal (cross-sectional)

Definición: mediciones en un momento (snapshot) para evaluar prevalencia/relación entre variables.

Keywords: “cross-sectional”, “survey”, “at baseline”, “prevalence”, “one time”, “convenience sample”.

Señales textuales rápidas en abstract / métodos para clasificar

- “cross-sectional”, “prevalence” → transversal.

Herramientas: AXIS

Downes, M. J., Brennan, M. L., Williams, H. C., & Dean, R. S. (2016). Development of a critical appraisal tool to assess the quality of cross-sectional studies (AXIS). *BMJ open*, *6*(12), e011458.

Estudio de precisión diagnóstica (Diagnostic accuracy / test accuracy)

Definición: evalúa sensibilidad/especificidad/ROC de un test índice frente a una referencia estándar.

Keywords: “sensitivity”, “specificity”, “AUC”, “reference standard”, “index test”, “diagnostic”.

Señales textuales rápidas en abstract / métodos para clasificar

“sensitivity”, “specificity”, “reference standard”, “index test” → diagnóstico.

Herramientas: QUADAS 2

QUADAS-2: Whiting et al., 2011.

Whiting, P. F., Rutjes, A. W., Westwood, M. E., Mallett, S., Deeks, J. J., Reitsma, J. B., ... & QUADAS-2 Group*. (2011). QUADAS-2: a revised tool for the quality assessment of diagnostic accuracy studies. *Annals of internal medicine*, *155*(8), 529-536.(original paper) https://www.acpjournals.org/doi/full/10.7326/0003-4819-155-8-201110180-00009 y herramienta en

Introducing QUADAS-3: an updated tool for assessing risk of bias in diagnostic test accuracy (DTA) reviews https://www.cochrane.org/events/introducing-quadas-3-tool

Huang, Q. X., & Huang, X. W. (2022). QUADAS-2 tool for quality assessment in diagnostic meta-analysis. *Annals of Palliative Medicine*, *11*(5), 1844845-1841845.

Estudio de caso, serie de casos (case report / case series)

Definición: descripción de uno (case report) o varios casos sin comparación sistemática.

Keywords:"case report", "case series", "we present a case", "n = 1 / small series".

Estudio de validación / reproducibilidad de instrumento (measurement / reliability study)

Definición: evalúa fiabilidad, reproducibilidad, propiedades métricas (ICC, SEM) de una medición/tech.

Keywords: "test–retest", "intra-rater / inter-rater reliability", "ICC", "precision", "validation".

Señales textuales rápidas en abstract / métodos para clasificar

- "ICC", "test–retest", "reliability" → estudio de fiabilidad.

Estudios de desarrollo o validación de modelos predictivos / machine learning

Definición: construyen y/o validan modelos que predicen outcomes; pueden incluir CV, external validation.

Keywords: "model", "predict", "machine learning", "training/validation/test set", "cross-validation", "AUC", "calibration", "external validation".

Señales textuales rápidas en abstract / métodos para clasificar

- “machine learning”, “model”, “training set”, “cross-validation” → model/predicción.

Herramientas: PROBAST

PROBAST (prediction model risk of bias): Wolff et al., 2019.

Wolff, R. F., Moons, K. G., Riley, R. D., Whiting, P. F., Westwood, M., Collins, G. S., ... & PROBAST Group†. (2019). PROBAST: a tool to assess the risk of bias and applicability of prediction model studies. *Annals of internal medicine*, *170*(1), 51-58.

https://www.acpjournals.org/doi/full/10.7326/M18-1377?download=true&journalCode=aim

Ultima versión: https://www.probast.org/

Moons KGM, Damen JAA, Kaul T, et al. PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. BMJ 2025;388:e082505 doi:10.1136/bmj-2024-082505

Estudio metodológico / técnico (methodological study)

Definición: desarrolla o prueba un procedimiento de medición/algoritmo, sin objetivo clínico principal.

Keywords: “method”, “algorithm”, “pipeline”, “technical validation”, “simulation”.

Herramientas: COSMIN

COSMIN: https://cosmin.nl/ (manual y checklist)

Tool Checklists for Assessing Study Qualities • COSMIN

Instructions: EE-document_version-1.1.pdf

Herramientas principales y cuándo usarlas

RoB 2 (Risk of Bias 2) — Estudios aleatorizados (RCT)

Uso: ensayos clínicos aleatorizados.

Dominios: randomización, desviaciones de la intervención, datos faltantes, medición del resultado, selección del reporte.

Referencia: Sterne et al., 2019 (BMJ).

Link:

ROBINS-I — Estudios no aleatorizados de intervención (NRSI / quasi-experimental)

Uso: intervenciones comparadas sin aleatorización (ej. asignación por clínica, antes/después con controles no randomizados).

Dominios: confusión, selección, clasificación de intervención, desviaciones, datos faltantes, medición de resultados, selección del reporte.

Referencia: Sterne et al., 2016 (BMJ).

Newcastle–Ottawa Scale (NOS) / adaptaciones — Estudios observacionales (cohortes y case–control)

Uso: cohortes y estudios caso control; común en revisiones epidemiológicas.

Dominios (simplificado): selección, comparabilidad, exposición/outcome.

Ventaja: simple;

Desventaja: menos detallada y subjetiva; muchas revisiones la usan.

Alternativas más modernas: ROBINS E (en desarrollo/uso) intenta adaptar ROBINS I para la exposición observacional.

Referencia: Wells et al. (NOS).

AXIS — Estudios transversales (cross-sectional)

Uso: estudios cross sectional (prevalencia, encuestas).

Dominios: objetivos, muestreo, mediciones, análisis, sesgo.

Referencia: Downes et al.

QUADAS 2 — Estudios de precisión diagnóstica

Uso: estudios que evalúan la sensibilidad/especificidad, la AUC y el test diagnóstico frente a la referencia.

Dominios: selección de pacientes, prueba de índice, prueba de referencia, flujo y tiempo; cada dominio para riesgo y aplicabilidad.

Referencia: Whiting et al., 2011.

PROBAST — Estudios de modelos predictivos / riesgo / ML (prognostic / diagnostic prediction models)

Uso: estudios de desarrollo, validación o actualización de modelos de predicción (incluye ML). Muy apropiado para modelos que predicen sarcopenia/screening.

Dominios: participantes, predictores, outcome, análisis (incluye overfitting, validación, manejo de valores faltantes, evaluación de rendimiento/calibración).

Se recomienda cuando hay estudios de ML que construyen modelos predictivos y se requiere evaluar el riesgo de sesgo estructural.

Referencia: Wolff et al., 2019.

COSMIN — Estudios sobre propiedades de medidas (instrumentos, PROMs, fiabilidad)

Uso: cuando el estudio evalúa propiedades psicométricas, repetibilidad, fiabilidad, validez de una medida.

Dominios: consistencia interna, fiabilidad, medición error, contenido, constructo, etc.

Referencia: COSMIN manual.

TRIPOD, Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis

Es una guía de reporte —no una herramienta de sesgo— diseñada para mejorar la transparencia y completitud en la publicación de estudios que desarrollan, validan o actualizan modelos de predicción (regresión multivariada o modelos basados en ML) para diagnóstico o pronóstico.

Objetivo: permitir que lectores, revisores y otros investigadores evalúen la validez, la utilidad y la reproducibilidad del estudio, y repliquen o validen modelos.

Uso: En estudios de desarrollo de modelos predictivos (prognostic o diagnostic).
En estudios de validación (internos o externos) de modelos ya publicados.
En estudios que actualizan o recalibran modelos predictivos.
Útil como checklist para autores, revisores y editores; complementa PROBAST (que evalúa riesgo de sesgo).

Dominios: TRIPOD es una lista de 22 items (con subitems) agrupados según las secciones habituales de un artículo científico. Aquí los dominios/elementos clave (abreviado)

Collins, G. S., Reitsma, J. B., Altman, D. G., & Moons, K. G. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): the TRIPOD statement. *Journal of British Surgery*, *102*(3), 148-158.

GRADE (no es RoB sino valoración de evidencia)

Uso: para resumir y valorar la certeza de la evidencia en síntesis (puedes usar GRADE o GRADE-CERQual, según corresponda).

Estrategia de uso para una revisión:

1. Clasifica cada estudio por su diseño (p. ej., RCT; no-RCT de intervención; cohort; case-control; cross-sectional; diagnostic accuracy; prognostic/prediction/ML; measurement/HD-sEMG methodological).

2. Asigna la herramienta adecuada:
   a. RCT → RoB 2.
   b. Intervención no RCT → ROBINS-I.
   c. Cohorte / caso-control → NOS (o ROBINS-E si está disponible) + considerar ajustar juicios con dominios de confusión.
   d. Estudios transversales → AXIS.
   e. Precisión diagnóstica → QUADAS-2.
   f. Modelos de predicción / aprendizaje automático → PROBAST (obligatorio para la calidad metodológica de los modelos).
   g. Estudios de propiedades del instrumento (protocolos de adquisición de señal, fiabilidad de las medidas de sEMG) → COSMIN (si aplica) o criterios metodológicos de validación técnica.

3. Evaluación práctica:
   a. Realizar evaluación por, al menos, dos revisores independientes.
   b. Resolver discrepancias por consenso o mediante un tercer revisor.
   c. Registrar juicios por dominio y justificar con citas textuales (p. ej. “no adjustment for confounding; no info on blinding of outcome assessors”).

4. Reporte:

a. Incluir tablas por estudio y por dominio (con juicios low/unclear/high RoB).
b. Si hay mezcla de diseños, presentar tablas separadas por tipo y resumir en texto.
c. Para ML/prognostic studies: reportar problemas clave (small sample, no external validation, lack of nested CV, leakage, missing CI for AUC, no calibration).